阶段 0：系统初始化

0.1 阶段目标

1. 定义系统场景与基本假设

2. 收集用户信息与 DNN 任务参数

3. 计算全局统计量，为后续归一化提供基准

4. 确定 UAV 数量并完成初始部署

5. 进行初始资源分配与质量评估

6. 输出系统初始状态，衔接后续阶段

0.2 场景定义与假设

应用场景

UAV 辅助边缘计算场景下的 DNN 协同推理。用户设备算力有限，需将 DNN 推理任务卸载到 UAV 边缘节点或云端执行。

关键假设

| 假设 | 说明 |

|------|------|

| UAV 同构性 | 所有 UAV 具有相同最大算力f^{max}和电池容量E^{max} |

| 固定飞行高度 | UAV 在固定高度H飞行，简化为二维部署问题 |

| LoS 信道 | 用户与 UAV 之间为视距信道，采用自由空间路径损耗模型 |

| 全程集中式控制 | 由 Service Provider（SP）全程集中式控制 |

| 位置可调整 | UAV 初始部署后，运行时可定期重定位 |

| SP 抽象资源主体 | SP 包含所有 UAV 与云端，计算能力有限，仅作为时间预算体现 |

Service Provider 定义

SP 为抽象资源主体，具备以下特性：包含所有 UAV 和云服务器，全局状态感知，直接扮演拍卖方角色，无需备份机制，计算能力有限体现为拍卖时间预算$T_{auction} \leq 100$ms。

通信模型说明

保留用户与 UAV 通信时延、UAV 与云端通信时延。忽略 UAV 之间通信（SP 内部协调）。

时间预算

| 阶段 | 时间约束 |

|------|----------|

| 系统初始化 | $T_{init} \approx 5\text{-}30$秒（离线） |

| 投标生成 | $T_{bid} \leq 200$ms |

| 拍卖决策 | $T_{auction} \leq 100$ms |

| 端到端调度 | $T_{total} < 1$秒 |

0.3 输入数据

用户集合与位置

$$\mathcal{U} = \{1, 2, \ldots, M\}$$

$$pos_i = (x_i, y_i) \in \mathbb{R}^2, \quad \forall i \in \mathcal{U}$$

DNN 任务参数

$$Task_i = (ModelID_i, InputSize_i, \mathcal{L}_i^{cut}, UserLevel_i)$$

| 参数 | 说明 |

|------|------|

| $ModelID_i$ | DNN 模型标识 |

| $InputSize_i$ | 输入数据大小（bits） |

| $\mathcal{L}_i^{cut}$ | 可选切分点集合，为$\{0, 1, ..., L\}$（所有层边界） |

| $UserLevel_i$ | 用户等级（1-5） |

DNN 模型结构信息（预存储）

每个模型预先分析并存储层级信息：

$$LayerProfile_m = \{(FLOPs_l, OutputSize_l)\}_{l=1}^{L_m}$$

| 参数 | 说明 |

|------|------|

| $FLOPs_l$ | 第l层计算量（浮点运算次数） |

| $OutputSize_l$ | 第l层输出特征图大小（bits） |

| L_m | 模型m的总层数 |

系统参数

| 参数 | 符号 | 典型值 | 说明 |

|------|------|--------|------|

| UAV 飞行高度 | H | 100m | 固定 |

| UAV 最大算力 | f^{max} | 10 GFLOPS | 同构 |

| UAV 电池容量 | E^{max} | 500kJ | 同构 |

| 信道带宽 | W | 20MHz | 单信道 |

| 参考信道增益 | β_0 | 10^{-6} | 1m 处 |

| 噪声功率谱密度 | N_0 | $10^{-17.4}$W/Hz | 热噪声 |

| 用户发射功率 | P_i^{tx} | 0.1W | 用户上行功率 |

| 云端总算力 | F_c | 500 GFLOPS | 云端资源池 |

| 回程链路带宽 | $R_{backhaul}$ | 100Mbps | UAV 到云端 |

| 边缘能耗系数 | κ_{edge} | 10^{-28} | 边缘计算能耗 |

| 云端能耗系数 | κ_{cloud} | 10^{-29} | 云端计算能耗 |

0.4 全局统计量计算

任务计算量统计

任务总计算量从 DNN 模型结构导出：

$$C_i^{total} = \sum_{l=1}^{L_{m_i}} FLOPs_l$$

统计量：

$$C_{min} = \min_{i \in \mathcal{U}} C_i^{total}, \quad C_{max} = \max_{i \in \mathcal{U}} C_i^{total}$$

输入大小统计

$$InputSize_{min} = \min_{i \in \mathcal{U}} InputSize_i, \quad InputSize_{max} = \max_{i \in \mathcal{U}} InputSize_i$$

用户等级统计

$$Level_{min} = \min_{i \in \mathcal{U}} UserLevel_i, \quad Level_{max} = \max_{i \in \mathcal{U}} UserLevel_i$$

以上统计量传递给阶段 1，用于优先级因子的归一化计算。

0.5 场景几何特征

用户分布边界

$$x_{min} = \min_i x_i, \quad x_{max} = \max_i x_i$$

$$y_{min} = \min_i y_i, \quad y_{max} = \max_i y_i$$

场景中心与半径

$$Center = \left(\frac{x_{min} + x_{max}}{2}, \frac{y_{min} + y_{max}}{2}\right)$$

$$R_{scene} = \frac{1}{2}\sqrt{(x_{max} - x_{min})^2 + (y_{max} - y_{min})^2}$$

用户质心

$$Centroid = \left(\frac{1}{M}\sum_{i=1}^{M} x_i, \frac{1}{M}\sum_{i=1}^{M} y_i\right)$$

场景面积与用户密度

$$A_{scene} = (x_{max} - x_{min}) \times (y_{max} - y_{min})$$

$$\rho_{users} = \frac{M}{A_{scene}}$$

0.6 UAV 数量确定

基于用户规模的确定规则

$$N = \begin{cases}

2 & \text{if } M \leq 20 \\

3 & \text{if } 20 < M \leq 50 \\

5 & \text{if } 50 < M \leq 100 \\

8 & \text{if } M > 100

\end{cases}$$

UAV 集合

$$\mathcal{N} = \{1, 2, \ldots, N\}$$

0.7 加权 K-means 部署

任务权重计算

权重反映任务紧迫度，使 UAV 更靠近高优先级用户：

$$w_i = \alpha_1 \cdot \frac{C_i^{total}}{\max_k C_k^{total}} + \alpha_2 \cdot \frac{InputSize_i}{\max_k InputSize_k}$$

推荐参数：$\alpha_1 = 0.7$，$\alpha_2 = 0.3$

权重归一化

$$\tilde{w}_i = \frac{w_i}{\sum_{k \in \mathcal{U}} w_k}$$

加权 K-means 目标函数

$$\min_{P, \pi} \sum_{j=1}^{N} \sum_{i: \pi(i)=j} \tilde{w}_i \cdot \|pos_i - P_j\|^2$$

其中$P = \{P_1, \ldots, P_N\}$为 UAV 位置集合，$P_j = (x_j, y_j)$；$\pi: \mathcal{U} \to \mathcal{N}$为用户到 UAV 的分配映射。

迭代更新

簇中心更新（加权质心）：

$$P_j = \frac{\sum_{i: \pi(i)=j} \tilde{w}_i \cdot pos_i}{\sum_{i: \pi(i)=j} \tilde{w}_i}$$

用户分配更新：

$$\pi(i) = \arg\min_{j \in \mathcal{N}} \|pos_i - P_j\|^2$$

收敛条件

$$\max_j \|P_j^{(t+1)} - P_j^{(t)}\| < \epsilon_{kmeans}$$

推荐$\epsilon_{kmeans} = 10^{-6}$，最大迭代 100 次。采用 K-means++初始化，按距离平方概率选择初始中心，避免局部最优。

0.8 通信模型

用户到 UAV 距离

$$d_{i,j} = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2 + H^2}$$

信道增益（自由空间路径损耗）

$$h_{i,j} = \frac{\beta_0}{d_{i,j}^2}$$

传输速率（香农公式）

$$R_{i,j} = W \log_2 \left(1 + \frac{P_i^{tx} \cdot h_{i,j}}{N_0 W}\right)$$

传输时延

$$T_i^{upload}(j) = \frac{InputSize_i}{R_{i,j}}$$

0.9 初始资源分配

目的

为后续阶段提供资源状态基准，评估部署质量。

可行性判断

UAV j对用户i可行当且仅当：

$$f_j^{avail} \geq f_i^{min}(j)$$

其中最小所需算力：

$$f_i^{min}(j) = \frac{C_i^{total}}{T_{ref} - T_i^{upload}(j)}$$

T_{ref}为参考时延（如 5 秒），用于初始分配评估。

贪心分配规则

1. 按任务计算密度$Density_i = C_i^{total} / InputSize_i$降序排列

2. 对每个任务选择最近可行 UAV

3. 分配算力并更新 UAV 剩余资源

负载率计算

$$L_j = \frac{f_j^{used}}{f_j^{max}} = \frac{\sum_{i: \pi(i)=j} f_{i,j}}{f_j^{max}}$$

0.10 初始化质量评估

任务覆盖率

$$CoverageRate = \frac{|\mathcal{U}_{assigned}|}{M}$$

平均 UAV 利用率

$$\bar{Util} = \frac{1}{N} \sum_{j=1}^{N} L_j$$

负载均衡指数（Jain's Fairness Index）

$$JFI = \frac{\left(\sum_{j=1}^{N} L_j\right)^2}{N \cdot \sum_{j=1}^{N} L_j^2}$$

取值$[1/N, 1]$，越接近 1 越均衡。

平均服务距离

$$\bar{d}_{service} = \frac{1}{|\mathcal{U}_{assigned}|} \sum_{i \in \mathcal{U}_{assigned}} d_{i, \pi(i)}$$

该值传递给阶段 4，作为 UAV 重定位触发的基准。

0.11 UAV 状态初始化

每个 UAV 的初始状态：

$$State_j = (P_j, f_j^{max}, f_j^{avail}, E_j^{remain}, L_j, LoadedModels_j)$$

| 参数 | 说明 | 初始值 |

|------|------|--------|

| P_j | UAV 位置(x_j, y_j) | K-means 输出 |

| f_j^{max} | 最大算力 | 系统参数 |

| f_j^{avail} | 当前可用算力 | $f_j^{max} - \sum_i f_{i,j}$ |

| E_j^{remain} | 剩余能量 | E^{max}（初始满电） |

| L_j | 负载率 | 贪心分配后计算 |

| $LoadedModels_j$ | 已加载模型集合 | $\emptyset$（初始为空） |

0.12 阶段 0 输出

传递给阶段 1 的数据

| 数据项 | 符号 | 说明 |

|--------|------|------|

| 用户集合 | $\mathcal{U}$ | 所有用户 |

| 任务参数 | $\{Task_i\}$ | 各用户任务信息 |

| UAV 集合 | $\mathcal{N}$ | UAV 编号集合 |

| UAV 位置 | $\{P_j\}_{j=1}^N$ | K-means 优化后的位置 |

| UAV 状态 | $\{State_j\}_{j=1}^N$ | 含算力、能量、负载 |

| 初始任务分配 | $\pi^{(0)}$ | 用户-UAV 映射 |

| 计算量统计 | C_{min}, C_{max} | 计算量归一化基准 |

| 输入大小统计 | $InputSize_{min}, InputSize_{max}$ | 数据量归一化基准 |

| 用户等级统计 | $Level_{min}, Level_{max}$ | 等级归一化基准 |

传递给阶段 2 的数据

| 数据项 | 符号 | 说明 |

|--------|------|------|

| DNN 模型库 | $\{LayerProfile_m\}$ | 各模型层结构信息 |

| UAV 位置 | $\{P_j\}$ | 距离与速率计算 |

| UAV 状态 | $\{f_j^{avail}, E_j^{remain}\}$ | 可行性判断 |

| 系统参数 | $H, W, \beta_0, N_0, R_{backhaul}$ | 通信与时延模型 |

| 能耗系数 | $\kappa_{edge}, \kappa_{cloud}$ | 能耗计算 |

传递给阶段 4 的数据

| 数据项 | 符号 | 说明 |

|--------|------|------|

| 平均服务距离 | $\bar{d}_{service}$ | UAV 重定位触发基准 |

| UAV 初始状态 | $\{State_j\}$ | 运行时监控初始值 |

| DNN 模型库 | $\{LayerProfile_m\}$ | Checkpoint 数据量计算 |

性能基线

| 指标 | 符号 | 说明 |

|------|------|------|

| 任务覆盖率 | $CoverageRate$ | 初始可服务比例 |

| 平均利用率 | $\bar{Util}$ | 资源利用效率 |

| 负载均衡指数 | JFI | 负载分布均匀性 |

阶段 1：任务优先级计算

1.1 阶段目标

1. 计算每个任务的综合优先级，用于后续效用计算和资源分配排序

2. 将任务按优先级分类，便于差异化处理

1.2 输入数据

| 数据项 | 符号 | 来源 | 用途 |

|--------|------|------|------|

| 用户集合 | $\mathcal{U}$ | 阶段 0 | 遍历计算优先级 |

| 任务参数 | $\{Task_i\}$ | 阶段 0 | 优先级因子计算 |

| 计算量统计 | C_{min}, C_{max} | 阶段 0 | 计算量归一化 |

| 输入大小统计 | $InputSize_{min}, InputSize_{max}$ | 阶段 0 | 数据量归一化 |

| 用户等级统计 | $Level_{min}, Level_{max}$ | 阶段 0 | 等级归一化 |

| UAV 状态 | $\{State_j\}$ | 阶段 0 | 传递给后续阶段 |

1.3 优先级因子定义

任务优先级综合考虑三个维度：

数据量因子

$$\omega_i^{data} = \begin{cases}

\dfrac{InputSize_i - InputSize_{min}}{InputSize_{max} - InputSize_{min}} & \text{if } InputSize_{max} \neq InputSize_{min} \\[10pt]

0 & \text{otherwise}

\end{cases}$$

计算量因子

$$\omega_i^{comp} = \begin{cases}

\dfrac{C_i^{total} - C_{min}}{C_{max} - C_{min}} & \text{if } C_{max} \neq C_{min} \\[10pt]

0 & \text{otherwise}

\end{cases}$$

用户等级因子

$$\omega_i^{level} = \begin{cases}

\dfrac{UserLevel_i - Level_{min}}{Level_{max} - Level_{min}} & \text{if } Level_{max} \neq Level_{min} \\[10pt]

0 & \text{otherwise}

\end{cases}$$

1.4 综合优先级计算

$$\omega_i = \alpha_1 \cdot \omega_i^{data} + \alpha_2 \cdot \omega_i^{comp} + \alpha_3 \cdot \omega_i^{level}$$

权重设置：

| 权重 | 值 | 设计理由 |

|------|-----|----------|

| α_1 | 0.25 | 数据量影响传输时延 |

| α_2 | 0.35 | 计算量影响资源需求 |

| α_3 | 0.40 | 用户等级反映任务重要性 |

约束：$\sum_{k=1}^{3} \alpha_k = 1$

优先级范围：$\omega_i \in [0, 1]$

边界情况处理

当所有因子均无区分度时（所有任务参数相同），按任务索引分配优先级：

$$\omega_i = \frac{M - i + 1}{M}, \quad \text{if } \forall k: \omega_k^{factor} = 0$$

1.5 任务分类

自适应分位数阈值

基于当前任务集的优先级分布动态确定阈值：

$$\theta_{high} = P_{80}(\{\omega_i\}_{i \in \mathcal{U}})$$

$$\theta_{medium} = P_{40}(\{\omega_i\}_{i \in \mathcal{U}})$$

其中$P_k(\cdot)$表示第k百分位数。

分类规则

$$\mathcal{U}_{high} = \{i \in \mathcal{U} : \omega_i \geq \theta_{high}\}$$

$$\mathcal{U}_{medium} = \{i \in \mathcal{U} : \theta_{medium} \leq \omega_i < \theta_{high}\}$$

$$\mathcal{U}_{low} = \{i \in \mathcal{U} : \omega_i < \theta_{medium}\}$$

完备性验证：

$$\mathcal{U}_{high} \cup \mathcal{U}_{medium} \cup \mathcal{U}_{low} = \mathcal{U}$$

$$\mathcal{U}_{high} \cap \mathcal{U}_{medium} = \mathcal{U}_{medium} \cap \mathcal{U}_{low} = \mathcal{U}_{high} \cap \mathcal{U}_{low} = \emptyset$$

分类统计

$$M_{high} = |\mathcal{U}_{high}|, \quad M_{medium} = |\mathcal{U}_{medium}|, \quad M_{low} = |\mathcal{U}_{low}|$$

分类与阶段 3 约束的衔接

| 任务类别 | 阶段 3 约束 | 含义 |

|---------|---------|---|

| $\mathcal{U}_{high}$ | $\sum_{l,j} x_{i,l,j} = 1$ | 必须被服务（在用户收益非负前提下） |

| $\mathcal{U}_{medium} \cup \mathcal{U}_{low}$ | $\sum_{l,j} x_{i,l,j} \leq 1$ | 可被拒绝 |

所有任务均需满足用户收益非负条件$U_i^{user} \geq 0$才能被服务。

1.6 用户收益模型

服务价值

$$V_i(l,j) = \omega_i \cdot \eta_{i,l,j}^{stage2}$$

其中$\eta_{i,l,j}^{stage2}$为阶段 2 计算的归一化综合效用。

价值范围：$V_i \in [0, 1]$

用户收益

$$U_i^{user}(l,j) = V_i(l,j) - P_{i,l,j} = \omega_i \cdot \eta_{i,l,j}^{stage2} - P_{i,l,j}$$

其中$P_{i,l,j}$为阶段 2 计算的归一化方案价格。

服务接受条件

$$Accept_{i,l,j} = \mathbb{1}(U_i^{user}(l,j) \geq 0)$$

价格不超过价值时才接受服务。

设计优势

| 特性 | 说明 |

|------|------|

| 任务自适应 | 时延基准根据任务计算量和数据量自动确定 |

| 无量纲化 | 价值和价格均归一化到$[0, 1]$范围 |

| 公平性 | 计算密集型任务不因绝对时延长而被歧视 |

| 激励相容 | 高效服务获得高价值，用户收益高 |

1.7 阶段 1 输出

传递给阶段 2 的数据

| 数据项 | 符号 | 说明 |

|--------|------|------|

| 任务优先级 | $\{\omega_i\}_{i \in \mathcal{U}}$ | 每个任务的综合优先级 |

| 任务分类 | $(\mathcal{U}_{high}, \mathcal{U}_{medium}, \mathcal{U}_{low})$ | 三个优先级集合 |

| 分类统计 | $(M_{high}, M_{medium}, M_{low})$ | 各类任务数量 |

| UAV 状态 | $\{State_j\}$ | 来自阶段 0，传递使用 |

传递给阶段 3 的数据

| 数据项 | 符号 | 说明 |

|--------|------|------|

| 任务优先级 | $\{\omega_i\}$ | 用于最终效用计算 |

| 任务分类 | $(\mathcal{U}_{high}, \mathcal{U}_{medium}, \mathcal{U}_{low})$ | 用于差异化约束 |

传递给阶段 4 的数据

| 数据项 | 符号 | 说明 |

|--------|------|------|

| 任务优先级 | $\{\omega_i\}$ | 用于运行时动态优先级计算 |

1.8 计算复杂度分析

| 环节 | 复杂度 | 说明 |

|------|--------|------|

| 优先级计算 | $O(M)$ | 遍历所有用户 |

| 分位数计算 | $O(M \log M)$ | 排序 |

| 任务分类 | $O(M)$ | 遍历比较阈值 |

| 总复杂度 | $O(M \log M)$ | 主要受分位数排序主导 |

时间预算：$T_{phase1} \approx 0.1$秒

阶段 2：投标生成与风险评估

2.1 阶段目标

1. 解析 DNN 模型结构，确定所有可选切分点
2. 对每个切分点与 UAV 组合，在云边独立资源约束下，通过解析式频率分配确定最计算资源
3. 计算时延、能耗，评估方案性能
4. 生成所有可行方案的投标，传输给 SP
5. 完成资源信息收集

2.2 输入数据

来自阶段 0

| 数据项 | 符号 | 用途 |

|--------|------|------|

| UAV 位置 | $\{P_j\}$ | 距离与速率计算 |

| UAV 状态 | $\{f_j^{avail}, E_j^{remain}\}$ | 可行性判断与解析式资源分配 |

| DNN 模型库 | $\{LayerProfile_m\}$ | 切分点分析 |

| 系统参数 | $H, W, \beta_0, N_0, P_i^{tx}, R_{backhaul}$ | 通信模型 |

| 能耗系数 | $\kappa_{edge}, \kappa_{cloud}$ | 能耗计算 |

来自阶段 1

| 数据项 | 符号 | 用途 |

|--------|------|------|

| 任务优先级 | $\{\omega_i\}$ | 传递给阶段 3 |

| 任务分类 | $\mathcal{U}_{high}, \mathcal{U}_{medium}, \mathcal{U}_{low}$ | 传递给阶段 3 |

来自阶段 4（非首轮，闭环反馈）

| 数据项 | 符号 | 用途 |

|--------|------|------|

| 资源利用率 | $\{Util_j\}$ | 价格计算与负载感知 |

| 模型加载状态 | $\{LoadedModels_j\}$ | 模型热度引导 |

2.3 DNN 模型解析

层级结构提取

对用户i的模型m_i，从模型库读取：

$$LayerProfile_{m_i} = \{(FLOPs_l, OutputSize_l)\}_{l=1}^{L}$$

| 参数 | 说明 |

|------|------|

| $FLOPs_l$ | 第l层计算量（浮点运算次数） |

| $OutputSize_l$ | 第l层输出特征图大小（bits） |

| L | 模型总层数 |

可选切分点集合

所有层边界均可作为切分点：

$$\mathcal{L}_i^{cut} = \{0, 1, 2, ..., L\}$$

共$L+1$个切分点。

切分点参数计算

对每个切分点$l \in \mathcal{L}_i^{cut}$：

边缘计算量（前l层）：

$$C_i^{edge}(l) = \sum_{k=1}^{l} FLOPs_k$$

云端计算量（后$L-l$层）：

$$C_i^{cloud}(l) = \sum_{k=l+1}^{L} FLOPs_k$$

传输数据量（第l层输出）：

$$D_i^{trans}(l) = OutputSize_l$$

特殊切分点：

| 切分点 | 含义 | 参数值 |

|--------|------|--------|

| $l = 0$ | 全云端 | $C_i^{edge}(0) = 0$，$D_i^{trans}(0) = InputSize_i$ |

| $l = L$ | 全边缘 | $C_i^{cloud}(L) = 0$，$D_i^{trans}(L) = 0$ |

Checkpoint 层约束

虽然所有层可切分，但 Checkpoint 建议在特定层执行：

$$\mathcal{L}_i^{cp} \subseteq \mathcal{L}_i^{cut}$$

适合 Checkpoint 的层：卷积层后、池化层后、批归一化后。不适合 Checkpoint 的层：残差块内部、注意力机制中间。

Checkpoint 层选择：

$$l_{cp,i} = \max\{l' : l' \in \mathcal{L}_i^{cp}, l' \leq l_i^*\}$$

即选择不超过切分层的最大可 Checkpoint 层。

2.4 通信模型

用户到 UAV 链路

三维距离：

$$d_{i,j} = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2 + H^2}$$

信道增益（自由空间路径损耗）：

$$h_{i,j} = \frac{\beta_0}{d_{i,j}^2}$$

传输速率（香农公式）：

$$R_{i,j} = W \log_2 \left(1 + \frac{P_i^{tx} \cdot h_{i,j}}{N_0 W}\right)$$

UAV 到云端链路

回程链路速率（固定）：

$$R_{j,cloud} = R_{backhaul}$$

典型值：$R_{backhaul} = 100$ Mbps

UAV 选择原则

用户选择通信时延最低的 UAV 作为首选：

$$j_{prefer}(i) = \arg\min_{j \in \mathcal{N}} \frac{InputSize_i}{R_{i,j}}$$

2.5 时延模型

完整时延公式

$$T_i^{total}(l, j) = T_i^{upload} + T_i^{edge}(l, j) + T_i^{trans}(l) + T_i^{cloud}(l) + T_i^{return}(l)$$

各分量严格顺序执行:

分量	公式	说明
上传时延	$T_i^{upload} = \dfrac{InputSize_i}{R_{i,j}}$	用户→UAV
边缘计算时延	$T_i^{edge}(l, j) = \dfrac{C_i^{edge}(l)}{f_{i,j}^*}$	UAV 执行 1~l层
中继传输时延	$T_i^{trans}(l) = \dfrac{D_i^{trans}(l)}{R_{backhaul}}$	UAV→云端
云端计算时延	$T_i^{cloud}(l) = \dfrac{C_i^{cloud}(l)}{f_{c,i}^*}$	云端执行$l+1$~L层
返回时延	$T_i^{return}(l)$	云端→UAV→用户

返回时延定义

$$T_i^{return}(l) = \mathbb{1}(l < L) \cdot \frac{OutputSize_L}{R_{backhaul}} + \frac{OutputSize_L}{R_{i,j}}$$

模式	返回时延
全边缘（$l=L$）	$\frac{OutputSize_L}{R_{i,j}}$（仅 UAV→用户）
协作/全云端（$l<L$）	$\frac{OutputSize_L}{R_{backhaul}} + \frac{OutputSize_L}{R_{i,j}}$（云→UAV→用户）

三种卸载模式统一表达

模式	切分层	时延公式
全边缘	$l = L$	$T = T^{upload} + T^{edge}(L) + T^{return}(L)$
协作	$0 < l < L$	$T = T^{upload} + T^{edge}(l) + T^{trans}(l) + T^{cloud}(l) + T^{return}(l)$

| 全云端 | $l = 0$ | $T = T^{upload} + T^{trans}(0) + T^{cloud}(0) + T^{return}(0)$ |

串行时延的物理依据

DNN 推理的数据依赖性：

$$Output_l = Layer_l(Output_{l-1})$$

云端执行第$l+1$层需要第l层的完整输出，因此边缘必须先完成第l层计算，第l层输出必须完整传输到云端，云端才能开始第$l+1$层计算。

2.6 边云独立能量预算下的解析式频率分配

对给定 (i, l, j)，令

$$C_e = C_i^{\text{edge}}(l), \qquad C_c = C_i^{\text{cloud}}(l).$$

最小化计算时延：

$$\min_{f_e, f_c} \quad \frac{C_e}{f_e} + \frac{C_c}{f_c}$$

约束改为独立预算：

$$0 \le f_e \le f_j^{\text{ava}}, \qquad \kappa_{\text{edge}} f_e^2 C_e \le E_{e,j}^{\text{budget}},$$
$$0 \le f_c \le F_c^{\text{ava}}, \qquad \kappa_{\text{cloud}} f_c^2 C_c \le E_{c,i}^{\text{budget}}.$$

其中边缘预算：

$$E_{e,j}^{\text{budget}} = \min\left(E_j^{\text{ava}}, P_j^{\text{comp,bdg}}\right),$$
$$P_j^{\text{comp,bdg}} = \left(P_j^{\max} - P_j^{\text{hover}}\right) T_{\text{window}},$$

云端预算：

$$E_{c,i}^{\text{budget}} = \theta_i^c P_c^{\max} T_{\text{window}},$$

$$\theta_i^c = \frac{\omega_i C_i^{\text{cloud}}(l)}{\sum_{k \in \mathcal{U}^{\text{cand}}} \omega_k C_k^{\text{cloud}}(l_k) + \varepsilon}.$$

新的解析解

由于目标函数关于 f_e, f_c 单调递减，最优频率直接由各自可行域上界给出：

$$f_e^* = \begin{cases} \min\left(f_j^{\text{ava}}, \sqrt{\dfrac{E_{e,j}^{\text{budget}}}{\kappa_{\text{edge}} C_e}}\right), & C_e > 0, \\ 0, & C_e = 0, \end{cases}$$

$$f_c^* = \begin{cases} \min\left(F_c^{\text{ava}}, \sqrt{\dfrac{E_{c,i}^{\text{budget}}}{\kappa_{\text{cloud}} C_c}}\right), & C_c > 0, \\ 0, & C_c = 0. \end{cases}$$

进一步代入 θ_i^c 后：

$$f_c^* = \begin{cases} \min\left(F_c^{\text{ava}}, \sqrt{\dfrac{\omega_i P_c^{\max} T_{\text{window}}}{\kappa_{\text{cloud}} \left(\sum_{k \in \mathcal{U}^{\text{cand}}} \omega_k C_k^{\text{cloud}}(l_k) + \varepsilon\right)}}\right), & C_c > 0, \\ 0, & C_c = 0. \end{cases}$$

2.8 综合风险评估

综合风险因子

$$\gamma_{i,l,j} = w_{energy} \cdot \gamma^{energy} + w_{channel} \cdot \gamma^{channel} + w_{compute} \cdot \gamma^{compute}$$

各分量：

$$\gamma^{energy} = Clip\left(1 - \frac{E_j^{remain} - E_i^{total}}{E_{safety}}, 0, 1\right)$$

$$\gamma^{channel} = Clip\left(1 - \frac{R_{i,j} - R_{min}}{R_{margin}}, 0, 1\right)$$

$$\gamma^{compute} = Clip\left(\frac{f_{i,j}^*}{f_j^{avail}}, 0, 1\right)$$

权重设置:

权重	值	理由
w_{energy}	0.40	能量是任务失败主因之一
$w_{channel}$	0.35	信道影响传输可靠性
$w_{compute}$	0.25	算力过载通常可预测

2.9 统一价格模型

设计原则

资源充裕时价格趋近于零，资源稀缺时价格指数上升，完全基于比值实现无量纲化。

利用率定义

边缘算力利用率:

$$u_j^{comp} = 1 - \frac{f_j^{avail}}{f_j^{max}}$$

云端算力利用率：

$$u^{cloud} = 1 - \frac{F_c^{avail}}{F_c}$$

能量利用率：

$$u_j^{energy} = 1 - \frac{E_j^{remain}}{E_j^{max}}$$

信道利用率：

$$u_s = \mathbb{1}(\text{信道}s\text{正在使用})$$

所有利用率$u \in [0, 1]$。

归一化单位价格

$$P_j^{comp,norm} = \frac{\exp(\alpha \cdot u_j^{comp}) - 1}{\exp(\alpha) - 1}$$

$$P^{cloud,norm} = \frac{\exp(\alpha \cdot u^{cloud}) - 1}{\exp(\alpha) - 1}$$

$$P_j^{energy,norm} = \frac{\exp(\alpha \cdot u_j^{energy}) - 1}{\exp(\alpha) - 1}$$

$$P_s^{channel,norm} = \frac{\exp(\alpha \cdot u_s) - 1}{\exp(\alpha) - 1}$$

所有归一化单位价格$\in [0, 1]$。推荐$\alpha = 3$。

价格特性（$\alpha = 3$）：

| 利用率u | P^{norm} | 含义 |

|----------|----------|------|

| 0 | 0 | 资源完全空闲，免费 |

| 0.3 | 0.077 | 低负载 |

| 0.5 | 0.182 | 中等负载 |

| 0.7 | 0.372 | 高负载 |

| 0.9 | 0.732 | 接近满载 |

| 1.0 | 1.0 | 满载 |

归一化资源使用量

$$r_{i,j}^{comp} = \frac{f_{i,j}^*}{f_j^{max}}, \quad r_i^{cloud} = \frac{f_{c,i}^*}{F_c}, \quad r_{i,j}^{energy} = \frac{E_i^{total}}{E_j^{max}}, \quad r_s = \mathbb{1}(\text{使用信道}s)$$

所有归一化资源使用量$r \in [0, 1]$。

方案总价格

$$P_{i,l,j} = \frac{1}{4} \left(P_j^{comp,norm} \cdot r_{i,j}^{comp} + P^{cloud,norm} \cdot r_i^{cloud} + P_j^{energy,norm} \cdot r_{i,j}^{energy} + P_s^{channel,norm} \cdot r_s \right)$$

除以 4（资源类型数量）使总价格归一化。

2.10 时延基准与效用计算

任务时延基准（任务自适应）

系统参数估计：

$$R^{avg} = W \log_2\left(1 + \frac{P^{tx} \cdot \beta_0}{(\bar{d}_{service}^2 + H^2) \cdot N_0 W}\right)$$

$$f^{avg} = \frac{1}{N} \sum_{j \in \mathcal{N}} f_j^{avail}, \quad f_c^{avg} = \frac{F_c}{M}$$

任务时延基准：

$$T_i^{baseline} = \frac{InputSize_i + OutputSize_L}{R^{avg}} + \frac{C_i^{total}}{f^{avg} + f_c^{avg}}$$

每个任务基于其计算量和数据量自动得到合理的时延基准。

归一化时延比

$$\tau_i(l,j) = \frac{T_i^{total}(l,j)}{T_i^{baseline}}$$

含义：$\tau_i < 1$表示实际时延优于基准，高价值；$\tau_i = 1$表示实际时延等于基准，中等价值；$\tau_i > 1$表示实际时延劣于基准，低价值。

时延效用

$$U_{time,i}(l,j) = \exp(-\beta \cdot \tau_i(l,j)) = \exp\left(-\beta \cdot \frac{T_i^{total}(l,j)}{T_i^{baseline}}\right)$$

推荐$\beta = 2$。

时延效用特性：

τ_i	$U_{time,i}$	含义
0.25	0.61	时延远优于基准
0.5	0.37	时延为基准一半

| 1.0 | 0.14 | 时延等于基准 |

| 1.5 | 0.05 | 时延超过基准 50% |

| 2.0 | 0.02 | 时延为基准两倍 |

能效效用

$$U_{energy,i}(l,j) = \max\left(0, 1 - \frac{E_i^{total}(l,j)}{E_i^{budget}}\right)$$

可靠性效用

$$U_{reliability,i}(l,j) = 1 - \gamma_{i,l,j}$$

阶段 2 综合效用

$$\eta_{i,l,j}^{stage2} = \beta_1 \cdot U_{time,i} + \beta_2 \cdot U_{energy,i} + \beta_3 \cdot U_{reliability,i}$$

权重设置:

| 权重 | 值 | 理由 |

|------|-----|------|

| β_1 | 0.45 | 时延是核心优化目标 |

| β_2 | 0.25 | 能效影响系统续航 |

| β_3 | 0.30 | 可靠性保障任务完成 |

效用范围: $\eta_{i,l,j}^{stage2} \in [0, 1]$

2.11 服务价值与用户收益

服务价值

$$V_i(l,j) = \omega_i \cdot \eta_{i,l,j}^{stage2}$$

价值范围：$V_i \in [0, 1]$

用户收益

$$U_i^{user}(l,j) = V_i(l,j) - P_{i,l,j} = \omega_i \cdot \eta_{i,l,j}^{stage2} - P_{i,l,j}$$

服务接受条件

$$Accept_{i,l,j} = \mathbb{1}(U_i^{user}(l,j) \geq 0)$$

只有用户收益非负的方案才能被选中。

2.12 候选方案生成

遍历所有切分点与可行 UAV 组合：

$$\mathcal{B}_i = \{(l, j) : l \in \mathcal{L}_i^{cut}, j \in \mathcal{N}_i^{feasible}(l)\}$$

其中$\mathcal{N}_i^{feasible}(l)$为对切分点$l$可行的 UAV 集合，满足算力约束和能量约束。

所有可行方案均作为投标提交给 SP。

价格引导采样（非首轮）

若有资源状态反馈，调整 UAV 选择概率：

$$P(j | Feedback) \propto \frac{1}{P_j^{comp}} \cdot \frac{1}{d_{i,j}^2} \cdot (1 - Util_j) \cdot \mathbb{1}(m_i \in LoadedModels_j)$$

调整逻辑：价格高的 UAV 被选中概率降低，距离远的 UAV 被选中概率降低，负载重的 UAV 被选中概率降低，已加载所需模型的 UAV 被选中概率提高。

2.13 投标封装

投标字段

字段	符号	类型	说明
用户 ID	i	整数	任务发起者
模型 ID	m_i	整数	DNN 模型标识
切分层	l	整数	切分点位置
目标 UAV	j	整数	边缘执行节点
边缘计算量	$C_i^{edge}(l)$	实数	前l层 FLOPs
云端计算量	$C_i^{cloud}(l)$	实数	后$L-l$层 FLOPs
传输数据量	$D_i^{trans}(l)$	实数	第l层输出大小
请求边缘算力	$f_{i,j}^*$	实数	分配结果
请求云端算力	$f_{c,i}^*$	实数	分配结果
预测时延	$T_{i,l,j}$	实数	总时延
总能耗	$E_{i,l,j}^{total}$	实数	方案总能耗
风险因子	$\gamma_{i,l,j}$	实数	综合风险

| 效用值 | $\eta_{i,l,j}^{stage2}$ | 实数 | 阶段 2 效用 |

| 方案价格 | $P_{i,l,j}$ | 实数 | 统一价格模型计算 |

| 时间戳 | t_{gen} | 时间 | 生成时间 |

投标结构

$$Bid_{i,b} = (i, m_i, l, j, C^{edge}, C^{cloud}, D^{trans}, f_{i,j}^*, f_{c,i}^*, T, E, \gamma, \eta, P, t_{gen})$$

2.14 投标传输

传输路径

用户选择通信时延最低的 UAV 作为中继，将投标传输给 SP：

$$j_{relay}(i) = \arg\min_{j \in \mathcal{N}} \frac{InputSize_i}{R_{i,j}}$$

$$Path_i: User_i \to UAV_{j_{relay}} \to SP$$

传输确认

SP 确认接收所有投标后，进入阶段 3。

2.15 资源信息收集

收集时机

投标生成后，SP 直接获取所有 UAV 状态。

收集内容

$$ResourceState = \{f_j^{avail}, E_j^{remain}, LoadedModels_j, Util_j\}_{j \in \mathcal{N}}$$

收集目的

为阶段 3 提供最新资源状态，支持约束检查与拍卖决策。

2.16 阶段 2 输出

传递给阶段 3 的数据

数据项	符号	说明
所有用户投标集	$\{\mathcal{B}_i\}_{i \in \mathcal{U}}$	所有可行方案
任务优先级	$\{\omega_i\}$	来自阶段 1，传递使用
任务分类	$(\mathcal{U}_{high}, \mathcal{U}_{medium}, \mathcal{U}_{low})$	来自阶段 1，传递使用
模型结构信息	$\{LayerProfile_m\}$	用于理解切分决策
资源状态	$\{f_j^{avail}, E_j^{remain}, Util_j\}$	SP 收集的最新状态

传递给阶段 4 的数据

数据项	符号	说明

| 最优算力分配 | $(f_{i,j}^*, f_{c,i}^*)$ | 执行时算力配置 |

| 方案价格 | $P_{i,l,j}$ | 用户收益计算 |

| 风险因子 | $\gamma_{i,l,j}$ | 运行时风险监控 |

2.17 计算复杂度分析

| 环节 | 复杂度 | 说明 |

|------|--------|------|

| DNN 解析 | $O(L)$ | 遍历模型层 |

| 候选方案生成 | $O((L+1) \times N)$ | 所有切分点×所有 UAV |

| 解析式求解 | $O(1)$ | 每方案闭型解 |

| 风险评估 | $O(1)$ | 每方案常数时间 |

| 价格计算 | $O(1)$ | 每方案常数时间 |

| 效用计算 | $O(1)$ | 每方案常数时间 |

| 单用户总复杂度 | $O(L \cdot N)$ | 主要受候选方案数主导 |

| 全系统复杂度 | $O(M \cdot L \cdot N)$ | 所有用户 |

时间预算：$T_{bid} \leq 200$ms，可满足。

阶段 3：社会福利最大化与组合拍卖

3.1 阶段目标

1. 在资源约束下选择最优切分方案组合，最大化系统整体效用（社会福利）
2. 保障高优先级任务必须被服务（在用户收益非负前提下），中低优先级任务可被拒绝
3. 通过拉格朗日对偶分解实现求解
4. 处理约束冲突，通过多策略贪心恢复获得可行解
5. 基于用户收益进行最终服务决策

6. 完成资源分配与价格确定

3.2 输入数据

来自阶段 1

数据项	符号	用途
任务优先级	$\{\omega_i\}_{i \in \mathcal{U}}$	最终效用计算
任务分类	$(\mathcal{U}_{high}, \mathcal{U}_{medium}, \mathcal{U}_{low})$	差异化约束

来自阶段 2

数据项	符号	用途
投标集	$\{\mathcal{B}_i\}_{i \in \mathcal{U}}$	拍卖输入
投标详情	$(l, j, C^{edge}, C^{cloud}, D^{trans}, f_{i,j}^*, f_{c,i}^*, \gamma, \eta^{stage2}, P_{i,l,j}, \ldots)$	约束检查与效用计算
模型结构信息	$\{LayerProfile_m\}$	理解切分决策
资源状态	$\{f_j^{avail}, E_j^{remain}, Util_j\}$	约束右端项与价格计算

系统资源状态

数据项	符号	用途
UAV 可用算力	$\{f_j^{avail}\}_{j \in \mathcal{N}}$	算力约束
UAV 可用能量	$\{E_j^{avail}\}_{j \in \mathcal{N}}$	能量约束
可用信道集	$\mathcal{S}$	信道约束

| 云端总算力 | F_c | 云端约束 |

| UAV 模型加载限制 | M_j^{max} | 模型约束 |

| UAV 功率预算 | $P_j^{comp,budget}$ | 瞬时功率约束 |

3.3 决策变量

$$x_{i,l,j} \in \{0, 1\}, \quad \forall i \in \mathcal{U}, l \in \mathcal{L}_i^{cut}, j \in \mathcal{N}$$

| 取值 | 含义 |

|------|------|

| $x_{i,l,j} = 1$ | 用户i选择切分层l、目标 UAV j的方案被接受 |

| $x_{i,l,j} = 0$ | 该方案未被接受 |

决策空间大小：

$$|x| = \sum_{i \in \mathcal{U}} |\mathcal{B}_i|$$

典型值：$M = 50$用户，每用户约$(L+1) \times N$个方案。

3.4 最终效用计算

效用融合公式

$$\eta_{i,l,j}^{final} = \omega_i \cdot \eta_{i,l,j}^{stage2}$$

各分量来源:

分量	来源	含义
ω_i	阶段 1	任务静态优先级
$\eta_{i,l,j}^{stage2}$	阶段 2	时延+能效+可靠性综合效用

效用值范围

$$\eta_{i,l,j}^{final} \in [0, 1]$$

3.5 用户收益计算

服务价值

$$V_i(l,j) = \omega_i \cdot \eta_{i,l,j}^{stage2}$$

用户收益

$$U_i^{user}(l,j) = V_i(l,j) - P_{i,l,j} = \omega_i \cdot \eta_{i,l,j}^{stage2} - P_{i,l,j}$$

其中$P_{i,l,j}$为阶段 2 计算的归一化方案价格。

服务接受条件

$$Accept_{i,l,j} = \mathbb{1}(U_i^{user}(l,j) \geq 0)$$

只有用户收益非负的方案才能被选中。

3.6 目标函数

社会福利最大化

$$\max_{x} \quad SW = \sum_{i \in \mathcal{U}} \sum_{l \in \mathcal{L}_i^{cut}} \sum_{j \in \mathcal{N}} \eta_{i,l,j}^{final} \cdot x_{i,l,j}$$

物理含义

社会福利是所有中标方案效用值的总和，反映系统整体服务质量。最大化社会福利意味着在资源约束下，尽可能多地服务高价值任务。

3.7 约束条件

高优先级任务强制服务约束

$$\sum_{l \in \mathcal{L}_i^{cut}} \sum_{j \in \mathcal{N}} x_{i,l,j} = 1, \quad \forall i \in \mathcal{U}_{high}$$

高优先级任务必须被服务，恰好选择一个方案。附加条件：所选方案必须满足$U_i^{user}(l,j) \geq 0$。

中低优先级任务唯一性约束

$$\sum_{l \in \mathcal{L}_i^{cut}} \sum_{j \in \mathcal{N}} x_{i,l,j} \leq 1, \quad \forall i \in \mathcal{U}_{medium} \cup \mathcal{U}_{low}$$

中低优先级任务最多选择一个方案，允许被拒绝。

UAV 算力容量约束

$$\sum_{i \in \mathcal{U}} \sum_{l \in \mathcal{L}_i^{cut}} f_{i,j}^* \cdot x_{i,l,j} \leq f_j^{avail}, \quad \forall j \in \mathcal{N}$$

每个 UAV 分配的算力不超过可用容量，使用解析解$f_{i,j}^*$。

信道互斥约束

$$\sum_{i \in \mathcal{U}} \sum_{l \in \mathcal{L}_i^{cut}} \sum_{j: s_{i,l,j}=s, s \neq 0} x_{i,l,j} \leq 1, \quad \forall s \in \mathcal{S}$$

每个独占信道同时只能服务一个任务。$s = 0$表示不需要独占信道，不受此约束。

UAV 能量容量约束

$$\sum_{i \in \mathcal{U}} \sum_{l \in \mathcal{L}_i^{cut}} E_{i,l,j}^{total} \cdot x_{i,l,j} \leq E_j^{avail}, \quad \forall j \in \mathcal{N}$$

每个 UAV 消耗的能量不超过可用能量。

云端算力容量约束

$$\sum_{i \in \mathcal{U}} \sum_{l \in \mathcal{L}_i^{cut}} \sum_{j \in \mathcal{N}} f_{c,i}^* \cdot x_{i,l,j} \leq F_c$$

所有使用云端的任务消耗总算力不超过云端容量，使用凸优化最优解$f_{c,i}^*$。

模型加载约束

$$\sum_{m \in \mathcal{M}} y_{j,m} \leq M_j^{max}, \quad \forall j \in \mathcal{N}$$

每个 UAV 同时加载的不同模型数量有限。

辅助变量定义：

$$y_{j,m} = \mathbb{1}(\exists i, l: m_i = m \land x_{i,l,j} = 1)$$

线性化处理：

$$\sum_{i: m_i = m} \sum_{l} x_{i,l,j} \leq K \cdot y_{j,m}, \quad \forall j, m$$

$$y_{j,m} \in \{0, 1\}$$

典型值：$M_j^{max} = 3\text{-}5$个模型。

二值约束

$$x_{i,l,j} \in \{0, 1\}, \quad \forall i, l, j$$

瞬时功率约束

$$\sum_{i \in \mathcal{U}} \sum_{l \in \mathcal{L}_i^{cut}} \kappa_{edge} \cdot (f_{i,j}^*)^3 \cdot x_{i,l,j} \leq P_j^{comp,budget}, \quad \forall j \in \mathcal{N}$$

其中：

$$P_j^{comp,budget} = (P_j^{max} - P_j^{hover}) \cdot T_{window}$$

| 参数 | 典型值 | 说明 |

|------|--------|------|

| P_j^{max} | 300W | UAV 总功率上限 |

| P_j^{hover} | 150W | 悬停功率 |

| T_{window} | 1s | 时间窗口 |

| $P_j^{comp,budget}$ | 150J | 计算功率预算 |

用户收益非负约束

$$x_{i,l,j} = 1 \Rightarrow U_i^{user}(l,j) \geq 0$$

只有用户收益非负的方案才能被选中。

3.8 约束条件汇总

$$\begin{aligned}

& \sum_{l,j} x_{i,l,j} = 1, \quad \forall i \in \mathcal{U}_{high} & \text{(C1a)} \\[5pt]

& \sum_{l,j} x_{i,l,j} \leq 1, \quad \forall i \in \mathcal{U}_{medium} \cup \mathcal{U}_{low} & \text{(C1b)} \\[5pt]

& \sum_{i,l} f_{i,j}^* \cdot x_{i,l,j} \leq f_j^{avail}, \quad \forall j & \text{(C2)} \\[5pt]

& \sum_{i,l,j: s_{i,l,j}=s} x_{i,l,j} \leq 1, \quad \forall s \neq 0 & \text{(C3)} \\[5pt]

& \sum_{i,l} E_{i,l,j}^{total} \cdot x_{i,l,j} \leq E_j^{avail}, \quad \forall j & \text{(C4)} \\[5pt]

& \sum_{i,l,j} f_{c,i}^* \cdot x_{i,l,j} \leq F_c & \text{(C5)} \\[5pt]

& \sum_{m} y_{j,m} \leq M_j^{max}, \quad \forall j & \text{(C6)} \\[5pt]

& x_{i,l,j} \in \{0, 1\} & \text{(C7)} \\[5pt]

& \sum_{i,l} \kappa_{edge} (f_{i,j}^*)^3 x_{i,l,j} \leq P_j^{comp,budget}, \quad \forall j & \text{(C8)} \\[5pt]

& x_{i,l,j} = 1 \Rightarrow U_i^{user}(l,j) \geq 0 & \text{(C9)}

\end{aligned}$$

3.9 高优先级强制约束的可行性保障

问题

强制约束 C1a 可能导致优化问题无可行解：资源不足时无法满足所有高优先级任务，或所有方案均导致用户收益为负。

软约束松弛

引入惩罚变量$z_i \geq 0$：

$$\sum_{l,j} x_{i,l,j} + z_i = 1, \quad \forall i \in \mathcal{U}_{high}$$

修正目标函数：

$$\max_{x,z} \quad SW - M_{penalty} \cdot \sum_{i \in \mathcal{U}_{high}} z_i$$

其中$M_{penalty}$为足够大的惩罚系数，推荐$M_{penalty} = 100$。

物理含义：$z_i > 0$表示高优先级任务i未被满足，受到巨大惩罚。

云端兜底强制

对于无法被 UAV 服务的高优先级任务，尝试使用云端：

若$\mathcal{N}_i^{feasible} = \emptyset$且$i \in \mathcal{U}_{high}$，则尝试$x_{i,0,j_{relay}} = 1$，其中

$j_{relay} = \arg\min_j d_{i,j}$为通信时延最低的 UAV 作为中继。仍需满足用户收益非负条件。

3.10 预处理：用户收益筛选

收益筛选

$$\mathcal{B}_i^{valid} = \{(l,j) \in \mathcal{B}_i : U_i^{user}(l,j) \geq 0\}$$

筛选条件展开

$$U_i^{user}(l,j) = \omega_i \cdot \eta_{i,l,j}^{stage2} - P_{i,l,j} \geq 0$$

等价于：

$$P_{i,l,j} \leq \omega_i \cdot \eta_{i,l,j}^{stage2}$$

即方案价格不超过服务价值。

无可行方案处理

若用户i的所有方案均被剔除（$\mathcal{B}_i^{valid} = \emptyset$），高优先级任务触发软约束松弛，中低优先级任务直接标记为拒绝。

3.11 完整优化问题

$$\begin{aligned}

\max_{x,z} \quad & SW = \sum_{i,l,j} \eta_{i,l,j}^{final} \cdot x_{i,l,j} - M_{penalty} \sum_{i \in \mathcal{U}_{high}} z_i \\[10pt]

\text{s.t.} \quad & \sum_{l,j} x_{i,l,j} + z_i = 1, \quad \forall i \in \mathcal{U}_{high} \\[5pt]

& \sum_{l,j} x_{i,l,j} \leq 1, \quad \forall i \in \mathcal{U}_{medium} \cup \mathcal{U}_{low} \\[5pt]

& \sum_{i,l} f_{i,j}^* x_{i,l,j} \leq f_j^{avail}, \quad \forall j \\[5pt]

& \sum_{i,l,j: s=s_{i,l,j}} x_{i,l,j} \leq 1, \quad \forall s \neq 0 \\[5pt]

& \sum_{i,l} E_{i,l,j}^{total} x_{i,l,j} \leq E_j^{avail}, \quad \forall j \\[5pt]

& \sum_{i,l,j} f_{c,i}^* x_{i,l,j} \leq F_c \\[5pt]

& \sum_m y_{j,m} \leq M_j^{max}, \quad \forall j \\[5pt]

& x_{i,l,j} \in \{0,1\}, \quad z_i \geq 0 \\[5pt]

& \sum_{i,l} \kappa_{edge}(f_{i,j}^*)^3 x_{i,l,j} \leq P_j^{comp,budget}, \quad \forall j \\[5pt]

& x_{i,l,j} \leq \mathbb{1}(U_i^{user}(l,j) \geq 0)

\end{aligned}$$

问题性质：0-1 整数线性规划（0-1 ILP），NP-hard。

3.12 拉格朗日对偶分解

引入对偶变量

对耦合约束引入拉格朗日乘子：

| 约束 | 对偶变量 | 维度 | 经济学含义 |

|------|----------|------|----------|

| C2（UAV 算力） | $\lambda_j \geq 0$ | N | UAV j算力影子价格 |

| C3（信道） | $\mu_s \geq 0$ | $|\mathcal{S}|$ | 信道s影子价格 |

| C4（UAV 能量） | $\nu_j \geq 0$ | N | UAV j能量影子价格 |

| C5（云端算力） | $\xi \geq 0$ | 1 | 云端算力影子价格 |

| C6（模型加载） | $\psi_{j,m} \geq 0$ | $N \times |\mathcal{M}|$ | 模型加载影子价格 |

| C8（瞬时功率） | $\phi_j \geq 0$ | N | UAV j功率影子价格 |

拉格朗日函数

$$\begin{aligned}

L(x, \lambda, \mu, \nu, \xi, \psi, \phi) = & \sum_{i,l,j} \eta_{i,l,j}^{final} \cdot x_{i,l,j} \\[5pt]

& - \sum_{j} \lambda_j \left(\sum_{i,l} f_{i,j}^* x_{i,l,j} - f_j^{avail} \right) \\[5pt]

& - \sum_{s} \mu_s \left(\sum_{i,l,j: s_{i,l,j}=s} x_{i,l,j} - 1 \right) \\[5pt]

& - \sum_{j} \nu_j \left(\sum_{i,l} E_{i,l,j}^{total} x_{i,l,j} - E_j^{avail} \right) \\[5pt]

& - \xi \left(\sum_{i,l,j} f_{c,i}^* x_{i,l,j} - F_c \right) \\[5pt]

& - \sum_{j,m} \psi_{j,m} \left(\sum_{i: m_i=m} \sum_l x_{i,l,j} - M_j^{max,m} \right) \\[5pt]

& - \sum_{j} \phi_j \left(\sum_{i,l} \kappa_{edge}(f_{i,j}^*)^3 x_{i,l,j} - P_j^{comp,budget} \right)

\end{aligned}$$

调整后效用

重新整理，按$x_{i,l,j}$分组：

$$\tilde{\eta}_{i,l,j} = \eta_{i,l,j}^{final} - \lambda_j f_{i,j}^* - \nu_j E_{i,l,j}^{total} - \phi_j \kappa_{edge}(f_{i,j}^*)^3 - \mu_{s_{i,l,j}} \cdot \mathbb{1}(s_{i,l,j} \neq 0) - \xi f_{c,i}^* - \psi_{j, m_i}$$

物理含义：调整后效用 = 原效用 - 资源使用成本（影子价格）。

对偶函数

$$g(\lambda, \mu, \nu, \xi, \psi, \phi) = \max_{x \in \mathcal{X}} L(x, \lambda, \mu, \nu, \xi, \psi, \phi)$$

可行域$\mathcal{X}$仅含约束 C1a、C1b、C7 和 C9（局部约束）：

$$\mathcal{X} = \left\{ x : \sum_{l,j} x_{i,l,j} = 1, \forall i \in \mathcal{U}_{high}; \sum_{l,j} x_{i,l,j} \leq 1, \forall i \in \mathcal{U}_{medium} \cup \mathcal{U}_{low}; x_{i,l,j} \in \{0,1\}; U_i^{user} \geq 0 \right\}$$

对偶问题

$$\min_{\lambda \geq 0, \mu \geq 0, \nu \geq 0, \xi \geq 0, \psi \geq 0, \phi \geq 0} g(\lambda, \mu, \nu, \xi, \psi, \phi)$$

3.13 子问题分解与求解

问题分解

由于约束 C1 使用户之间独立，对偶函数可分解为M个子问题：

$$g(\cdot) = \sum_{i \in \mathcal{U}} V_i^*(\lambda, \mu, \nu, \xi, \psi, \phi) + \text{Const}$$

用户子问题

高优先级用户（$i \in \mathcal{U}_{high}$）：

$$V_i^* = \max_{(l,j) \in \mathcal{B}_i^{valid}} \tilde{\eta}_{i,l,j}$$

必须从收益非负的方案中选择一个。

中低优先级用户（$i \in \mathcal{U}_{medium} \cup \mathcal{U}_{low}$）：

$$V_i^* = \max\left(0, \max_{(l,j) \in \mathcal{B}_i^{valid}} \tilde{\eta}_{i,l,j}\right)$$

可以选择不服务（效用为 0）。

闭式解

最优方案选择：

$$(l_i^*, j_i^*) = \arg\max_{(l,j) \in \mathcal{B}_i^{valid}} \tilde{\eta}_{i,l,j}$$

决策规则：

对于高优先级用户：

$$x_{i,l,j}^* = \mathbb{1}[(l,j) = (l_i^*, j_i^*)]$$

若$\mathcal{B}_i^{valid} = \emptyset$，则$z_i = 1$（触发惩罚）。

对于中低优先级用户：

$$x_{i,l,j}^* = \begin{cases}
1 & \text{if } (l,j) = (l_i^*, j_i^*) \text{ and } \tilde{\eta}_{i,l_i^*,j_i^*} > 0 \\
0 & \text{otherwise}
\end{cases}$$

物理含义：高优先级用户必须从收益非负方案中选择调整后效用最高者；中低优先级用户若最大调整后效用为正且收益非负则接受，否则拒绝。

3.14 次梯度法求解对偶问题

次梯度计算

给定当前解$x^{(t)}$:

UAV 算力次梯度:

$$g_{\lambda_j}^{(t)} = \sum_{i,l} f_{i,j}^* \cdot x_{i,l,j}^{(t)} - f_j^{avail}$$

信道次梯度:

$$g_{\mu_s}^{(t)} = \sum_{i,l,j: s_{i,l,j}=s} x_{i,l,j}^{(t)} - 1$$

UAV 能量次梯度:

$$g_{\nu_j}^{(t)} = \sum_{i,l} E_{i,l,j}^{total} \cdot x_{i,l,j}^{(t)} - E_j^{avail}$$

云端算力次梯度:

$$g_{\xi}^{(t)} = \sum_{i,l,j} f_{c,i}^* \cdot x_{i,l,j}^{(t)} - F_c$$

模型加载次梯度:

$$g_{\psi_{j,m}}^{(t)} = \sum_{i: m_i=m} \sum_l x_{i,l,j}^{(t)} - M_j^{max,m}$$

瞬时功率次梯度:

$$g_{\phi_j}^{(t)} = \sum_{i,l} \kappa_{edge} (f_{i,j}^*)^3 \cdot x_{i,l,j}^{(t)} - P_j^{comp,budget}$$

次梯度含义：$g > 0$表示资源超载，需提高影子价格；$g < 0$表示资源闲置，可降低影子价格；$g = 0$表示供需平衡。

对偶变量更新

步长序列（Polyak 步长）:

$$\epsilon^{(t)} = \frac{\epsilon_0}{t + 1}$$

推荐$\epsilon_0 = 0.5$。

更新规则:

$$\lambda_j^{(t+1)} = \left[\lambda_j^{(t)} + \epsilon^{(t)} \cdot g_{\lambda_j}^{(t)} \right]^+$$

$$\mu_s^{(t+1)} = \left[\mu_s^{(t)} + \epsilon^{(t)} \cdot g_{\mu_s}^{(t)} \right]^+$$

$$\nu_j^{(t+1)} = \left[\nu_j^{(t)} + \epsilon^{(t)} \cdot g_{\nu_j}^{(t)} \right]^+$$

$$\xi^{(t+1)} = \left[\xi^{(t)} + \epsilon^{(t)} \cdot g_{\xi}^{(t)} \right]^+$$

$$\psi_{j,m}^{(t+1)} = \left[\psi_{j,m}^{(t)} + \epsilon^{(t)} \cdot g_{\psi_{j,m}}^{(t)} \right]^+$$

$$\phi_j^{(t+1)} = \left[\phi_j^{(t)} + \epsilon^{(t)} \cdot g_{\phi_j}^{(t)} \right]^+$$

投影算子$[\cdot]^+$确保非负性。

收敛条件

主收敛条件为次梯度范数足够小:

$$\|g^{(t)}\|_2 < \epsilon_{tol}$$

推荐$\epsilon_{tol} = 10^{-4}$。

辅助停止条件：达到最大迭代次数$t \geq T_{max}$（推荐$T_{max} = 100$），或连续无改进（社会福利改进率小于阈值持续$patience$次）。

收敛速度：$O(1/\epsilon_{tol}^2)$次迭代。

3.15 迭代流程

Step 1：初始化。

$$\lambda_j^{(0)} = 0, \quad \mu_s^{(0)} = 0, \quad \nu_j^{(0)} = 0, \quad \xi^{(0)} = 0, \quad \psi_{j,m}^{(0)} = 0, \quad \phi_j^{(0)} = 0$$

Step 2：预处理。对每个用户i，筛选收益非负的投标：

$$\mathcal{B}_i^{valid} = \{(l,j) \in \mathcal{B}_i : U_i^{user}(l,j) \geq 0\}$$

Step 3：迭代主循环。对每次迭代$t = 0, 1, \ldots, T_{max}-1$：对每个用户计算调整后效用$\tilde{\eta}_{i,l,j}$，求解子问题选择最优方案$(l_i^*, j_i^*)$，计算次梯度，更新对偶变量，检查收敛条件。

Step 4：输出最优解。保存迭代过程中社会福利最高的可行解。

3.16 多策略贪心恢复

问题描述

对偶分解得到的解可能违反耦合约束，需进行可行性恢复。

违反度量：

$$V_j^{compute} = \max\left(0, \sum_{i,l} f_{i,j}^* x_{i,l,j} - f_j^{avail}\right)$$

$$V_s^{channel} = \max\left(0, \sum_{i,l,j: s_{i,l,j}=s} x_{i,l,j} - 1\right)$$

$$V_j^{energy} = \max\left(0, \sum_{i,l} E_{i,l,j} x_{i,l,j} - E_j^{avail}\right)$$

$$V^{cloud} = \max\left(0, \sum_{i,l,j} f_{c,i}^* x_{i,l,j} - F_c\right)$$

$$V_j^{power} = \max\left(0, \sum_{i,l} \kappa_{edge}(f_{i,j}^*)^3 x_{i,l,j} - P_j^{comp,budget}\right)$$

多策略设计

执行多种排序策略的贪心分配，选择社会福利最高者：

策略 1（按优先级排序）：

$$SortKey_1(i) = \omega_i$$

优先服务高优先级任务。

策略 2（按效用密度排序）：

$$density_i = \frac{\max_{(l,j) \in \mathcal{B}_i^{valid}} \eta_{i,l,j}^{final}}{f_{i,l^*,j^*}^* / f^{max} + E_{i,l^*,j^*} / E^{max} + 0.1}$$

$$SortKey_2(i) = density_i$$

优先服务"性价比"高的任务。

策略 3（按资源需求排序，升序）:

$$resource_i = f_{i,l^*,j^*}^* + \frac{E_{i,l^*,j^*}}{E^{max}} \cdot f^{max}$$

$$SortKey_3(i) = resource_i$$

优先分配资源需求小的任务。

策略 4（混合评分排序）:

$$SortKey_4(i) = \omega_i \times density_i$$

策略 5（按切分效率排序）:

$$efficiency_i = \frac{\eta_{i,l^*,j^*}}{D_i^{trans}(l^*) + 1}$$

$$SortKey_5(i) = efficiency_i$$

优先分配传输效率高的任务。

策略 6（按用户收益排序）:

$$SortKey_6(i) = \max_{(l,j) \in \mathcal{B}_i^{valid}} U_i^{user}(l,j)$$

优先服务收益最高的任务。

贪心分配逻辑

对每种策略：

1. 初始化资源状态：$f_j^{remain} = f_j^{avail}$，$E_j^{remain} = E_j^{avail}$，$F_c^{remain} = F_c$，$P_j^{remain} = P_j^{comp,budget}$，$Channels^{used} = \emptyset$。

2. 按排序遍历用户，对每个用户：遍历其有效投标（按效用降序），检查约束（算力、能量、信道、云端、模型加载、功率），检查用户收益$U_i^{user}(l,j) \geq 0$，若通过则分配并扣减资源、累加社会福利，否则尝试下一个投标。

3. 高优先级强制处理：若高优先级任务无可行投标，标记$z_i = 1$。

4. 记录该策略的社会福利。

最优策略选择

$$SW_{best} = \max(SW_1, SW_2, SW_3, SW_4, SW_5, SW_6)$$

选择对应策略的分配结果作为最终解。

3.17 资源分配更新

已分配资源计算

$$f_j^{allocated} = \sum_{i \in \mathcal{U}_{accepted}, l: x_{i,l,j}=1} f_{i,j}^*$$

$$E_j^{allocated} = \sum_{i \in \mathcal{U}_{accepted}, l: x_{i,l,j}=1} E_{i,l,j}^{total}$$

$$F_c^{allocated} = \sum_{i \in \mathcal{U}_{accepted}} f_{c,i}^*$$

利用率更新

$$Util_j^{new} = \frac{f_j^{allocated}}{f_j^{max}}$$

价格更新

基于新利用率，使用统一价格模型重新计算资源价格，供阶段 4 和下一轮阶段 2 使用。

3.18 阶段 3 输出

传递给阶段 4 的数据

数据项	符号	说明
分配矩阵	$\hat{x}$	中标方案标识
接受任务集	$\mathcal{U}_{accepted}$	成功分配的用户
拒绝任务集	$\mathcal{U}_{rejected}$	未能分配的用户
任务配置	$\{(i, l_i^*, j_i^*)\}$	执行配置
资源分配	$\{f_{i,j}^*, f_{c,i}^*\}$	算力分配（来自阶段 2 解析解）
信道分配	$\{s_i^*\}$	信道分配
用户支付价格	$\{P_{i,l,j}\}$	中标价格

| 用户收益 | $\{U_i^{user}\}$ | 各用户收益 |

| 各 UAV 模型加载状态 | $\{LoadedModels_j\}$ | 已加载模型集 |

| 资源利用率 | $\{Util_j^{new}\}$ | 更新后利用率 |

反馈给阶段 2（下一轮闭环）

| 数据项 | 符号 | 说明 |

|--------|------|------|

| 资源利用率 | $\{Util_j\}$ | 价格计算与负载感知 |

| 模型加载状态 | $\{LoadedModels_j\}$ | 引导模型复用 |

性能指标

| 指标 | 公式 |

|------|------|

| 社会福利 | $SW = \sum_{accepted} \eta^{final}$ |

| 任务接受率 | $AcceptRate = \frac{|\mathcal{U}_{accepted}|}{M}$ |

| 高优先级接受率 | $AcceptRate_{high} = \frac{|\mathcal{U}_{accepted} \cap \mathcal{U}_{high}|}{|\mathcal{U}_{high}|}$ |

| 平均用户收益 | $\bar{U}^{user} = \frac{1}{|\mathcal{U}_{accepted}|} \sum_{i \in \mathcal{U}_{accepted}} U_i^{user}$ |

| UAV 算力利用率 | $Util_j^{compute} = \frac{f_j^{allocated}}{f_j^{avail}}$ |

| 云端利用率 | $Util^{cloud} = \frac{F_c^{allocated}}{F_c}$ |

3.19 计算复杂度分析

| 环节 | 复杂度 | 说明 |

|------|--------|------|

| 用户收益筛选 | $O(M \cdot |\mathcal{B}|)$ | 遍历所有投标 |

| 单次子问题求解 | $O(|\mathcal{B}_i^{valid}|)$ | 遍历有效投标 |

| 单次迭代 | $O(M \cdot |\mathcal{B}|)$ | 所有用户 |

| 次梯度计算 | $O(M \cdot |\mathcal{B}|)$ | 汇总决策 |

| 总迭代复杂度 | $O(T_{iter} \cdot M \cdot |\mathcal{B}|)$ | |

| 贪心恢复 | $O(6 \cdot M \cdot |\mathcal{B}|)$ | 6 策略×用户×投标 |

时间预算：$T_{auction} \leq 100$ms。SP 内部执行，无通信开销，可满足时间预算。

阶段 4：执行调度与运行时管理

4.1 阶段目标

1. 执行阶段 3 分配的任务，管理传输、计算流程
2. 基于主动推理框架进行实时感知-行动循环
3. 实时跟踪能耗与功率，确保物理约束满足
4. 动态监控系统状态，更新资源价格
5. 利用期望自由能预测故障，实现主动式任务迁移与 Checkpoint 决策
6. 定期调整 UAV 位置，适应用户分布变化
7. 完成资源信息更新，形成闭环反馈给阶段 2

4.2 输入数据

来自阶段 0

| 数据项 | 符号 | 用途 |

|--------|------|------|

| 平均服务距离 | $\bar{d}_{service}$ | 重定位触发基准 |

| DNN 模型库 | $\{LayerProfile_m\}$ | Checkpoint 数据量计算 |

| UAV 初始状态 | $\{State_j\}$ | 运行时监控初始值 |

来自阶段 1

| 数据项 | 符号 | 用途 |

|--------|------|------|

| 任务优先级 | $\{\omega_i\}$ | 运行时动态优先级计算 |

来自阶段 2

| 数据项 | 符号 | 用途 |

|--------|------|------|

| 最优算力分配 | $\{(f_{i,j}^*, f_{c,i}^*)\}$ | 执行时资源分配 |

| 方案价格 | $\{P_{i,l,j}\}$ | 用户收益计算 |

| 风险因子 | $\{\gamma_{i,l,j}\}$ | 运行时风险监控 |

来自阶段 3

| 数据项 | 符号 | 用途 |

|--------|------|------|

| 分配矩阵 | $\hat{x}$ | 确定执行方案 |

| 接受任务集 | $\mathcal{U}_{accepted}$ | 待执行任务 |

| 任务配置 | $\{(i, l_i^*, j_i^*, f_{i,j}^*, f_{c,i}^*, s_i^*)\}$ | 执行参数 |

| 用户支付价格 | $\{P_{i,l,j}\}$ | 收益验证 |

| 用户收益 | $\{U_i^{user}\}$ | 服务确认 |

| 模型加载状态 | $\{LoadedModels_j\}$ | 减少重复加载 |

| 资源利用率 | $\{Util_j\}$ | 初始利用率状态 |

4.3 任务状态管理

任务状态定义

$$State_i \in \{QUEUED, TRANSMITTING, COMPUTING, CHECKPOINTING, MIGRATING, COMPLETED, FAILED\}$$

状态转移

QUEUED 为初始状态，信道分配完成后转为 TRANSMITTING，上传完成后转为 COMPUTING。在计算过程中，若主动推理决策触发 Checkpoint 则转为 CHECKPOINTING，Checkpoint 完成后恢复为 COMPUTING。若主动推理决策触发迁移则转为 MIGRATING，迁移完成后在新 UAV 上恢复为 COMPUTING。计算完成并返回结果后转为 COMPLETED。UAV 故障或用户收益变负时转为 FAILED。

运行时动态优先级

$$Priority_i^{runtime}(t) = w_1 \cdot \omega_i + w_2 \cdot \frac{T_{ref} - t_{elapsed}}{T_{ref}} + w_3 \cdot (1 - \gamma_{i,l,j})$$

权重设置：

权重	值	说明
w_1	0.4	任务固有优先级（来自阶段 1）
w_2	0.4	剩余时间紧迫度（动态变化）
w_3	0.2	执行可靠性（来自阶段 2 风险因子）

其中T_{ref}为参考时延（如 5 秒），$t_{elapsed}$为已执行时间。

4.4 主动推理框架

状态空间定义

状态向量（5 维）:

$$\mathbf{s}_t = \begin{bmatrix} E_t \\ T_t \\ h_t \\ d_t \\ \sigma_t \end{bmatrix}$$

符号	含义	单位	范围
E_t	UAV 剩余能量	J	$[0, E^{max}]$
T_t	任务已用时间	s	$[0, T_{max}]$
h_t	UAV 健康度	-	$[0, 1]$
d_t	用户到 UAV 距离	m	$[0, d_{max}]$
σ_t	环境不确定性	-	$[0, 1]$

观测向量:

$$\mathbf{o}_t = \begin{bmatrix} \hat{E}_t \\ \hat{h}_t \\ q_t \\ w_t \end{bmatrix}$$

符号	含义	说明
$\hat{E}_t$	能量观测	带噪声的能量读数
$\hat{h}_t$	健康度观测	传感器检测值
q_t	信道质量	$R_{i,j}/R_{max}$归一化
w_t	环境因素	负载率、干扰等

行动空间定义

$$\mathcal{A} = \{ a_{continue}, a_{checkpoint}, a_{reduce}, a_{handover}, a_{abort} \}$$

行动	描述	对状态的影响
$a_{continue}$	维持当前任务配置	标准能耗、进度推进
$a_{checkpoint}$	保存当前 DNN 层状态	时间开销、降低恢复成本
a_{reduce}	降低计算频率	降低能耗、进度变慢
$a_{handover}$	请求任务迁移到其他 UAV	通信开销、可能失败
a_{abort}	放弃当前任务	任务失败、释放资源

生成模型

完整生成模型:

$$P(\tilde{o}, \tilde{s}, \pi) = P(\pi) \prod_{\tau=0}^{H} P(o_\tau | s_\tau) \cdot P(s_\tau | s_{\tau-1}, a_{\tau-1})$$

能量转移:

$$E_{t+1} = E_t - P(a_t) \cdot \Delta t - \epsilon_E$$

其中功率消耗与行动相关:

$$P(a) = \begin{cases}
P_{hover} + \kappa_{edge}(f_{i,j}^*)^3 & a = a_{continue} \\
P_{hover} + P^{write} & a = a_{checkpoint} \\
P_{hover} + \kappa_{edge}(f_{i,j}^* \cdot \eta_{reduce})^3 & a = a_{reduce} \\
P_{hover} + P^{comm} & a = a_{handover} \\

P_{fly} & a = a_{abort}

\end{cases}$$

时间转移:

$$T_{t+1} = T_t + \Delta t \cdot \kappa(a_t)$$

其中时间系数:

$$\kappa(a) = \begin{cases}

1.0 & a = a_{continue} \\

1.0 + \kappa_{cp} & a = a_{checkpoint} \\

1.0 / \eta_{reduce} & a = a_{reduce} \\

1.0 + \kappa_{handover} & a = a_{handover} \\

\infty & a = a_{abort}

\end{cases}$$

健康度转移:

$$h_{t+1} = h_t \cdot \lambda_h - \delta_h(a_t) + \epsilon_h$$

其中$\lambda_h \in (0.99, 1)$为自然衰减率，$\delta_h(a)$为行动导致的额外损耗。

似然模型（观测模型）:

$$P(o_t | s_t) = \mathcal{N}(o_t; g(s_t), \Sigma_o)$$

其中$g(s_t)$为观测函数，$\Sigma_o = \text{diag}(\sigma_E^2, \sigma_h^2, \sigma_q^2, \sigma_w^2)$为观测噪声协方差矩阵。

信念表示与更新

信念表示（高斯近似）:

$$Q(s_t) = \mathcal{N}(s_t; \mu_t, \Sigma_t)$$

预测步骤:

$$\mu_t^{-} = f(\mu_{t-1}, a_{t-1})$$

$$\Sigma_t^{-} = F_{t-1} \Sigma_{t-1} F_{t-1}^T + Q$$

更新步骤:

$$K_t = \Sigma_t^{-} G^T (G \Sigma_t^{-} G^T + \Sigma_o)^{-1}$$

$$\mu_t = \mu_t^{-} + K_t (o_t - g(\mu_t^{-}))$$

$$\Sigma_t = (I - K_t G) \Sigma_t^{-}$$

其中$G = \partial g / \partial s$为观测函数雅可比矩阵。

即时自由能计算

$$F_t = w_E \cdot F_t^{energy} + w_T \cdot F_t^{time} + w_h \cdot F_t^{health}$$

各分量定义:

能量自由能:

$$F_t^{energy} = -\log\left(\frac{E_t}{E_{required}}\right)$$

其中$E_{required}$为完成剩余任务所需能量。

时间自由能：

$$F_t^{time} = -\log\left(\frac{T_{max} - T_t}{T_{remaining}^{required}}\right)$$

其中$T_{remaining}^{required}$为完成剩余任务所需时间。

健康度自由能：

$$F_t^{health} = -\log(h_t \cdot q_t)$$

权重设置：

权重	值	说明
w_E	0.40	能量风险
w_T	0.40	时间风险
w_h	0.20	健康度风险

期望自由能计算

$$G(\pi) = \sum_{\tau=1}^{H} \gamma^{\tau} \cdot \left[F(\hat{s}_\tau^\pi) + \alpha \cdot \sigma_\tau^2 \right]$$

其中γ为折扣因子，H为预测时域，α为探索系数，σ_τ^2为预测不确定性。

实用价值项（风险规避）:

$$G_{pragmatic}(\pi) = \sum_{\tau=1}^{H} \gamma^{\tau} \cdot F(\hat{s}_\tau^\pi)$$

认知价值项（信息增益）:

$$G_{epistemic}(\pi) = \sum_{\tau=1}^{H} \gamma^{\tau} \cdot \sigma_\tau^2$$

轨迹预测

确定性轨迹预测:

$$\hat{s}_{\tau+1} = f(\hat{s}_\tau, a_\tau), \quad \tau = t, t+1, \ldots, t+H-1$$

不确定性传播（简化版本）:

$$\sigma_{\tau+1}^2 = \lambda_\sigma \cdot \sigma_\tau^2 + q(a_\tau)$$

其中$\lambda_\sigma > 1$表示不确定性随时间增长，$q(a)$为行动引入的额外不确定性。

行动选择

可行行动集:

$$\mathcal{A}_{feasible}(s_t) = \{a \in \mathcal{A} : C(s_t, a) \leq 0\}$$

约束检查:

| 行动 | 可行性条件 |

|------|----------|

| $a_{continue}$ | $E_t > P_{continue} \cdot \Delta t$ |

| $a_{checkpoint}$ | $E_t > P_{checkpoint} \cdot \Delta t$ |

| a_{reduce} | $E_t > P_{reduce} \cdot \Delta t$ |

| $a_{handover}$ | $\exists j' \in \mathcal{N}_{backup}$ |

| a_{abort} | 始终可行 |

确定性选择：

$$a^* = \arg\min_{a \in \mathcal{A}_{feasible}} G(a)$$

概率性选择（Softmax）：

$$P(a) = \frac{\exp(-\beta_{action} \cdot G(a))}{\sum_{a' \in \mathcal{A}_{feasible}} \exp(-\beta_{action} \cdot G(a'))}$$

推荐$\beta_{action} = 5.0$。

4.5 感知-行动循环

循环流程

Step 1（OBSERVE）：获取观测o_t，包括能量读数、健康度、信道质量、环境因素。

Step 2（PERCEIVE）：信念更新$Q(s_t) \leftarrow update(Q(s_{t-1}), o_t)$，计算即时自由能$F_t$。

Step 3（PREDICT）：对每个可行行动$a \in \mathcal{A}_{feasible}$，进行轨迹预测并计算期望自由能$G(a)$。

Step 4（ACT）：选择最优行动$a^* = \arg\min G(a)$，执行行动。

Step 5（UPDATE）：更新任务状态、资源状态、价格。

Step 6（LOOP）：若任务未完成，返回 Step 1。

循环周期与时间预算

循环周期：

$$T_{loop} = \Delta t = 0.5 \text{s}$$

时间预算分配：

步骤	时间分配	绝对时间
观测获取	5%	25ms
信念更新	15%	75ms
轨迹预测	40%	200ms
行动选择	30%	150ms
执行与记录	10%	50ms

自适应精度控制：

$$H_{effective} = \max\left(1, H \cdot \frac{T_{available}}{T_{budget}}\right)$$

4.6 执行调度流程

传输阶段

传输进度跟踪:

$$D_i^{transmitted}(t + \Delta t) = D_i^{transmitted}(t) + R_{i,j}(t) \cdot \Delta t$$

传输完成条件:

$$D_i^{transmitted} \geq InputSize_i$$

边缘计算阶段

计算进度跟踪（受行动影响）:

$$C_i^{computed}(t + \Delta t) = C_i^{computed}(t) + f_{i,j}^{effective}(t) \cdot \Delta t$$

其中有效算力:

$$f_{i,j}^{effective}(t) = \begin{cases}
f_{i,j}^* & a_t = a_{continue} \\
0 & a_t = a_{checkpoint} \\
f_{i,j}^* \cdot \eta_{reduce} & a_t = a_{reduce} \\
0 & a_t = a_{handover} \text{ 或 } a_{abort}
\end{cases}$$

边缘计算完成条件:

$$C_i^{computed} \geq C_i^{edge}(l_i^*)$$

中继传输阶段

中继传输完成时刻：

$$T_i^{relay,end} = T_i^{edge,end} + \frac{D_i^{trans}(l_i^*)}{R_{backhaul}}$$

云端计算阶段

云端计算完成时刻：

$$T_i^{cloud,end} = T_i^{relay,end} + \frac{C_i^{cloud}(l_i^*)}{f_{c,i}^*}$$

结果返回阶段

返回完成时刻：

$$T_i^{return,end} = T_i^{cloud,end} + \frac{OutputSize_L}{R_{backhaul}} + \frac{OutputSize_L}{R_{i,j}}$$

对于全边缘模式（$l_i^* = L$）：

$$T_i^{return,end} = T_i^{edge,end} + \frac{OutputSize_L}{R_{i,j}}$$

实际用户收益验证

任务完成后，验证实际用户收益：

$$U_i^{actual} = \omega_i \cdot \eta_{i,l,j}^{stage2,actual} - P_{i,l,j}$$

其中$\eta_{i,l,j}^{stage2,actual}$基于实际时延$T_i^{actual} = T_i^{finish} - T_i^{start}$计算。

4.7 Checkpoint 管理

Checkpoint 触发条件

基于主动推理行动选择：

$$Trigger_{cp} = (a^* = a_{checkpoint}) \land (CurrentLayer \in \mathcal{L}_i^{cp})$$

动态 Checkpoint 决策：当主动推理检测到风险升高（$G(a_{checkpoint}) < G(a_{continue})$）时触发。

Checkpoint 数据内容

$$S_i^{checkpoint}(l_{cp}) = OutputSize_{l_{cp}} + S_{metadata}$$

$S_{metadata} \approx 1$KB。

Checkpoint 执行流程

1. 暂停计算任务，状态转为 CHECKPOINTING
2. 序列化第l_{cp}层输出特征图
3. 写入本地存储
4. （可选）传输到备份节点
5. 状态恢复为 COMPUTING
6. 恢复计算任务

Checkpoint 时间开销

$$T_{cp,exec} = \gamma_{cp} \cdot OutputSize_{l_{cp}}$$

推荐$\gamma_{cp} = 0.1$ s/MB。

Checkpoint 能耗

$$E_{cp} = P^{write} \cdot T_{cp,exec}$$

推荐$P^{write} = 7$W。

Checkpoint 存储管理

存储位置选择：优先本地存储（若$S_i^{checkpoint} < S_{local,avail}$），其次邻近 UAV（若存在$j'$满足$d_{j,j'} < d_{safe}$且$H_{j'} > 0.5$），最后云端存储。

清理策略：任务完成后删除对应 Checkpoint。

4.8 能耗跟踪

瞬时功耗

$$P_j^{total}(t) = P_j^{comp}(t) + P_j^{comm}(t) + P_j^{hover}$$

计算功耗（考虑行动影响）：

$$P_j^{comp}(t) = \sum_{i \in Q_j^{active}(t)} \kappa_{edge} \cdot (f_{i,j}^{effective}(t))^3$$

通信功耗:

$$P_j^{comm}(t) = P^{rx} \cdot N_j^{receiving}(t) + P^{tx} \cdot N_j^{transmitting}(t)$$

悬停功耗:

$$P_j^{hover} \approx 150 \text{W}$$

累计能耗

$$E_j^{consumed}(t + \Delta t) = E_j^{consumed}(t) + P_j^{total}(t) \cdot \Delta t$$

剩余能量

$$E_j^{remain}(t) = E_j^{max} - E_j^{consumed}(t)$$

能量告警阈值

阈值类型	公式	触发动作
警告阈值	$E_j^{warning} = 0.2 \cdot E_j^{max}$	主动推理倾向a_{reduce}
临界阈值	$E_j^{critical} = 0.1 \cdot E_j^{max}$	主动推理倾向$a_{handover}$
紧急阈值	$E_j^{emergency} = 0.05 \cdot E_j^{max}$	强制a_{abort}

4.9 统一动态定价

实时利用率计算

边缘算力利用率:

$$u_j^{comp}(t) = \frac{\sum_{i \in Q_j^{active}(t)} f_{i,j}^{effective}(t)}{f_j^{max}}$$

云端算力利用率:

$$u^{cloud}(t) = \frac{\sum_{i \in Q_{cloud}^{active}(t)} f_{c,i}^*}{F_c}$$

能量利用率:

$$u_j^{energy}(t) = 1 - \frac{E_j^{remain}(t)}{E_j^{max}}$$

信道利用率:

$$u_s(t) = \mathbb{1}(\text{信道}s\text{正在使用})$$

归一化单位价格更新

$$P_j^{comp,norm}(t) = \frac{\exp(\alpha \cdot u_j^{comp}(t)) - 1}{\exp(\alpha) - 1}$$

$$P^{cloud,norm}(t) = \frac{\exp(\alpha \cdot u^{cloud}(t)) - 1}{\exp(\alpha) - 1}$$

$$P_j^{energy,norm}(t) = \frac{\exp(\alpha \cdot u_j^{energy}(t)) - 1}{\exp(\alpha) - 1}$$

$$P_s^{channel,norm}(t) = \frac{\exp(\alpha \cdot u_s(t)) - 1}{\exp(\alpha) - 1}$$

价格平滑更新

$$P^{smooth}(t) = \lambda_{smooth} \cdot P(t) + (1 - \lambda_{smooth}) \cdot P^{smooth}(t-1)$$

推荐$\lambda_{smooth} = 0.3$。

4.10 健康度监控

综合健康度

$$H_j = w_E \cdot H_j^{energy} + w_L \cdot H_j^{load} + w_C \cdot H_j^{comm}$$

权重设置:

权重	值	说明
w_E	0.5	能量健康度权重最高
w_L	0.3	负载健康度
w_C	0.2	通信健康度

健康度分量

能量健康度:

$$H_j^{energy} = \frac{E_j^{remain}}{E_j^{max}}$$

负载健康度:

$$H_j^{load}(t) = 1 - \frac{\sum_{i \in Q_j^{active}(t)} f_{i,j}^{effective}(t)}{f_j^{max}}$$

通信健康度:

$$H_j^{comm} = \begin{cases}

1 & \text{if } Q_j = \emptyset \\[5pt]

\dfrac{1}{|Q_j|} \sum_{i \in Q_j} \min\left(1, \dfrac{R_{i,j}}{R_{min}}\right) & \text{otherwise}

\end{cases}$$

状态分级

| 健康度范围 | 状态 | 主动推理倾向 |

|---|---|---|

| $H_j \geq 0.7$ | HEALTHY | $a_{continue}$ |

| $0.5 \leq H_j < 0.7$ | WARNING | $a_{checkpoint}$或a_{reduce} |

| $0.3 \leq H_j < 0.5$ | CRITICAL | $a_{handover}$ |

| $H_j < 0.3$ | FAILED | a_{abort} |

4.11 故障检测与主动迁移

故障预测

预测性故障检测：主动推理通过轨迹预测提前发现潜在故障。若存在$\tau \in [t, t+H]$使得$\hat{E}_\tau < E^{emergency}$或$\hat{h}_\tau < h_{critical}$，则标记为预测故障，主动推理倾向$a_{handover}$。

期望自由能异常检测：若$G(a_{continue}) > G_{threshold}$，则当前方案风险过高，需考虑迁移或中止。

故障检测

心跳检测:

$$Alive_j(t) = \begin{cases}

1 & \text{if } t - t_j^{last_heartbeat} \leq T_{heartbeat}^{timeout} \\

0 & \text{otherwise}

\end{cases}$$

推荐$T_{heartbeat}^{timeout} = 5$秒。

综合故障判定:

$$Fault_j = (Alive_j = 0) \lor (H_j < 0.3) \lor (E_j^{remain} < E_j^{emergency})$$

主动迁移触发

基于主动推理的主动迁移:

$$Trigger_{handover} = (a^* = a_{handover})$$

迁移条件展开:

$$a^* = a_{handover} \Leftrightarrow G(a_{handover}) < \min(G(a_{continue}), G(a_{checkpoint}), G(a_{reduce}))$$

备用 UAV 选择

候选集合:

$$\mathcal{N}_{backup}(i) = \{j \in \mathcal{N} \setminus \{j_{current}\} : H_j > 0.5 \land R_{i,j} \geq R_{min}

\land f_j^{avail} \geq f_i^{required}\}$$

备用 UAV 评分：

$$S_j^{backup}(i) = \alpha_1 \cdot H_j + \alpha_2 \cdot \frac{R_{i,j}}{R_{max}} + \alpha_3 \cdot \frac{f_j^{avail}}{f_j^{max}} + \alpha_4 \cdot \frac{E_j^{remain}}{E_j^{max}}$$

权重设置：

| 权重 | 值 | 说明 |

|------|-----|------|

| α_1 | 0.35 | 健康度优先 |

| α_2 | 0.25 | 通信质量 |

| α_3 | 0.20 | 算力可用性 |

| α_4 | 0.20 | 能量储备 |

最优备用 UAV：

$$j_{backup}^*(i) = \arg\max_{j \in \mathcal{N}_{backup}(i)} S_j^{backup}(i)$$

任务迁移模型

迁移总时延：

$$T_i^{migrate} = T_i^{handshake} + T_i^{state_transfer} + T_i^{reconnect} + T_i^{warmup}$$

状态传输时间：

$$T_i^{state_transfer} = \begin{cases}

\dfrac{OutputSize_{l_{cp}}}{R_{j_{current}, j_{backup}}} & \text{有 Checkpoint 且原 UAV 可达} \\[10pt]

\dfrac{OutputSize_{l_{cp}}}{R_{storage}} & \text{有 Checkpoint 且从存储恢复} \\[10pt]

0 & \text{无 Checkpoint（需重新执行）}

\end{cases}$$

恢复时延对比

有 Checkpoint 恢复：

$$\Delta T_{recovery}^{cp=1} = T_i^{migrate} + \frac{C_i^{edge}(l_i^*) - C_i^{edge}(l_{cp})}{f_{j_{backup}}}$$

仅需计算l_{cp}到l_i^*之间的层。

无 Checkpoint 恢复（重新执行）：

$$\Delta T_{recovery}^{cp=0} = T_i^{upload} + T_i^{edge} + T_i^{trans} + T_i^{cloud} + T_i^{return}$$

需要完全重新执行。

迁移后处理

1. 任务状态转为 COMPUTING（在新 UAV）
2. 信念状态传递给 SP 用于系统学习
3. 重新初始化主动推理循环
4. 验证迁移后用户收益

4.12 UAV 位置动态调整

触发条件

位置失效指标：

$$Mismatch(t) = \frac{1}{M} \sum_{i \in \mathcal{U}} \min_{j \in \mathcal{N}} d_{i,j}(t) - \bar{d}_{service}^{init}$$

触发规则：

$$Trigger_{reposition} = (Mismatch(t) > \delta_{pos} \cdot \bar{d}_{service}^{init})$$

推荐$\delta_{pos} = 0.3$。

重定位目标

复用阶段 0 的加权 K-means，但权重动态更新：

$$w_i(t) = \alpha_1 \cdot \frac{C_i}{C_{max}} + \alpha_2 \cdot \frac{InputSize_i}{InputSize_{max}} + \alpha_3 \cdot \mathbb{1}(i \in \mathcal{U}_{active})$$

新增α_3项使活跃用户获得更高权重。

移动约束

能量约束：

$$E_j^{fly}(P_j^{old} \to P_j^{new}) \leq E_j^{remain} - E_j^{reserve}$$

飞行能耗：

$$E_j^{fly} = P^{fly} \cdot \frac{\|P_j^{new} - P_j^{old}\|}{v_{fly}}$$

典型值：$P^{fly} = 200$W，$v_{fly} = 10$ m/s。若能量不足，该 UAV 保持原位。

移动期间任务处理

移动中 UAV 无法服务新任务。已分配任务若可在移动前完成则继续执行，否则触发主动推理 $a_{handover}$。

4.13 资源信息更新与闭环反馈

更新时机

每个主动推理循环周期Δt更新一次。

更新内容

资源状态：

$$f_j^{avail,new} = f_j^{max} - \sum_{i \in Q_j^{active}} f_{i,j}^{effective}$$

$$E_j^{remain,new} = E_j^{max} - E_j^{consumed}$$

利用率更新：

$$Util_j^{new} = \frac{\sum_{i \in Q_j^{active}} f_{i,j}^{effective}}{f_j^{max}}$$

反馈数据结构

| 字段 | 内容 | 说明 |

|------|------|------|

| compute_prices | $\{P_j^{comp,norm}(t)\}_{j \in \mathcal{N}}$ | 各 UAV 归一化边缘算力价格 |

| cloud_price | $P^{cloud,norm}(t)$ | 归一化云端算力价格 |

| energy_prices | $\{P_j^{energy,norm}(t)\}_{j \in \mathcal{N}}$ | 各 UAV 归一化能量价格 |

| channel_prices | $\{P_s^{channel,norm}(t)\}_{s \in \mathcal{S}}$ | 各信道归一化价格 |

| utilization | $\{u_j(t)\}_{j \in \mathcal{N}}$ | 各 UAV 利用率 |

| health_status | $\{H_j, Status_j\}_{j \in \mathcal{N}}$ | 健康状态 |

| loaded_models | $\{LoadedModels_j\}_{j \in \mathcal{N}}$ | 已加载模型 |

| timestamp | $t_{feedback}$ | 反馈时间戳 |

反馈周期

$$T_{feedback} = \max(T_{min}, \frac{1}{TaskArrivalRate})$$

推荐$T_{min} = 1$秒。

反馈应用

在阶段 2 投标生成时，根据反馈调整采样概率：

$$P(j | Feedback) \propto \frac{1}{P_j^{comp}} \cdot \frac{1}{d_{i,j}^2} \cdot (1 - Util_j) \cdot \mathbb{1}(m_i \in LoadedModels_j)$$

4.14 实时监控指标

系统级指标

| 指标 | 公式 | 说明 |

|------|------|------|

| 任务完成率 | $CompletionRate(t) = \frac{|\{i : State_i = COMPLETED\}|}{|\mathcal{U}_{accepted}|}$ | 成功比例 |

| 平均响应时延 | $\bar{T}_{response}(t) = \frac{1}{|\mathcal{U}_{completed}|} \sum_{i} T_i^{actual}$ | 平均时延 |

| 系统吞吐量 | $Throughput(t) = \frac{\sum_{i \in \mathcal{U}_{completed}} C_i^{total}}{t}$ | 计算效率 |

| 故障率 | $FailureRate(t) = \frac{|\{i : State_i = FAILED\}|}{|\mathcal{U}_{accepted}|}$ | 失败比例 |

| 主动迁移率 | $MigrationRate(t) = \frac{N_{handover}}{|\mathcal{U}_{accepted}|}$ | 迁移比例 |

主动推理指标

| 指标 | 公式 | 说明 |

|------|------|------|

| 平均即时自由能 | $\bar{F}(t) = \frac{1}{|Q^{active}|} \sum_i F_i(t)$ | 当前风险水平 |

| 平均期望自由能 | $\bar{G}(t) = \frac{1}{|Q^{active}|} \sum_i G_i(a_i^*)$ | 预测风险水平 |

| 行动分布 | $Dist(a) = \frac{count(a)}{total}$ | 各行动选择比例 |

| 信念收敛度 | $Conv(t) = \frac{1}{|Q^{active}|} \sum_i \text{tr}(\Sigma_i(t))$ | 状态估计确定性 |

Checkpoint 与迁移指标

| 指标 | 公式 |

|------|------|

| Checkpoint 触发率 | $CPRate(t) = \frac{N_{checkpoint}}{N_{decisions}}$ |

| 平均 Checkpoint 时间 | $\bar{T}_{cp}(t) = \frac{\sum_{cp} T_{cp,exec}}{N_{checkpoint}}$ |

| 迁移成功率 | $MigSuccessRate(t) = \frac{N_{mig,success}}{N_{mig,attempted}}$ |

| 平均迁移时延 | $\bar{T}_{mig}(t) = \frac{\sum_{mig} T_{migrate}}{N_{mig}}$ |

用户收益指标

| 指标 | 公式 |

|------|------|

| 平均用户收益 | $\bar{U}^{user}(t) = \frac{1}{|\mathcal{U}_{completed}|} \sum_{i \in \mathcal{U}_{completed}} U_i^{actual}$ |

| 收益正比例 | $PositiveRate(t) = \frac{|\{i : U_i^{actual} \geq 0\}|}{|\mathcal{U}_{completed}|}$ |

告警机制

| 级别 | 条件 | 动作 |

|------|------|------|

| INFO | 正常状态变化 | 记录日志 |

| WARNING | $H_j < 0.5$或$E_j < E_{warning}$ | 降低任务接入 |

| CRITICAL | $H_j < 0.3$或$E_j < E_{critical}$ | 触发故障切换 |

4.15 阶段 4 输出

执行结果输出

| 数据项 | 说明 |

|--------|------|

| 完成任务集 | $\mathcal{U}_{completed}$ |

| 失败任务集 | $\mathcal{U}_{failed}$ |

| 迁移任务集 | $\mathcal{U}_{migrated}$ |

| 各任务执行详情 | $(T_i^{actual}, E_i^{actual}, U_i^{actual}, recovered?, cp_used?, migrated?, actions_taken)$ |

性能统计输出

数据项	说明
平均时延	$\bar{T}_{response}$
系统总能耗	$E_{system} = \sum_j E_j^{consumed} + E_{cloud}^{consumed}$
完成率	$CompletionRate$
高优先级完成率	$CompletionRate_{high}$
平均用户收益	$\bar{U}^{user}$
Checkpoint 统计	执行次数、恢复成功率、平均恢复时延

传递给下一轮阶段 2 的反馈

数据项	符号	用途
资源价格	$\{P_j^{comp}, P^{cloud}, P_j^{energy}, P_s^{channel}\}$	价格引导投标
资源利用率	$\{Util_j\}$	负载感知
UAV 健康状态	$\{H_j\}$	可行性判断
模型加载状态	$\{LoadedModels_j\}$	模型热度引导
位置更新	$\{P_j^{new}\}$（若重定位）	距离计算更新

4.16 计算复杂度分析

环节	复杂度	说明
观测获取	$O(1)$	常数时间
信念更新	$O(d^2)$	d为状态维度（5）
轨迹预测	$O(H \cdot |\mathcal{A}|)$	每行动预测H步
期望自由能计算	$O(H \cdot |\mathcal{A}|)$	每行动H步

| 行动选择 | $O(|\mathcal{A}|)$ | 遍历行动 |

| 单循环复杂度 | $O(H \cdot |\mathcal{A}|)$ | 约$10 \times 5 = 50$次操作 |

时间预算：每循环$\Delta t = 500$ms，计算时间< 200ms，满足实时性要求。

全局参数汇总

| 参数 | 推荐值 | 所属模块 | 说明 |

|------|--------|----------|------|

| α | 3 | 价格模型 | 稀缺性指数 |

| β | 2 | 效用计算 | 时延效用衰减系数 |

| $\beta_1, \beta_2, \beta_3$ | 0.45, 0.25, 0.30 | 效用计算 | 效用权重 |

| λ_{smooth} | 0.3 | 动态定价 | 价格平滑系数 |

| ρ | $(\kappa_c/\kappa_e)^{1/3}$ | 凸优化 | 边云算力比例 |

| H | 10 | 主动推理 | 预测时域 |

| Δt | 0.5 s | 主动推理 | 循环周期 |

| γ | 0.9 | 主动推理 | 折扣因子 |

| $\alpha_{explore}$ | 0.1 | 主动推理 | 探索系数 |

| β_{action} | 5.0 | 主动推理 | 逆温度 |

| w_E, w_T, w_h | 0.40, 0.40, 0.20 | 自由能 | 分量权重 |

| η_{reduce} | 0.6 | 行动 | 功率降低效率 |

| κ_{cp} | 0.1 | 行动 | Checkpoint 时间系数 |

| $\kappa_{handover}$ | 0.3 | 行动 | 迁移时间系数 |

| λ_σ | 1.05 | 轨迹预测 | 不确定性增长率 |

| λ_h | 0.995 | 状态转移 | 健康度衰减率 |

| $G_{threshold}$ | 120 | 期望自由能 | 期望自由能参考阈值 |

| σ_E | $0.01 \cdot E^{max}$ | 噪声 | 能量观测噪声 |

| σ_h | 0.02 | 噪声 | 健康度观测噪声 |

| σ_q | 0.05 | 噪声 | 信道质量噪声 |

| σ_w | 0.05 | 噪声 | 环境因素噪声 |